

DOKUMENTACJA BIBLIOTEKA AUTOMATYCZNEJ ANOTACJI OBIEKTÓW

Projekt Zespołowy



WERONIKA SIERACKA (248977) ALEKSANDER GÓRECKI (249003) SEBASTIAN ROBAK (248994)

1. Wstęp

Biblioteka do automatycznej anotacji danych została stworzona przy współpracy z firmą Samsung. Projekt ma za zadanie umożliwić i zautomatyzować korzystanie z metody uczenia Active Learning przy wykorzystaniu dowolnego detektora.

2. Założenia projektu

- Biblioteka nie wymaga połączenia z Internetem do działania,
- Biblioteka powinna mieć możliwość rozbudowy do potrzeb przyszłych użytkowników (klientów),
- Wprowadzanie zmian oraz rozwój kolejnych komponentów jest możliwie proste od strony developerskiej,
- Logika tej biblioteki ma być prosta w obsłudze

3. Wykorzystane technologie

- Język programowania: Python 3.8.5
- Środowisko programistyczne: PyCharm Community 2021.1
- System operacyjny: Linux Ubuntu 20.04 LTS
- GitHub

4. Wykorzystane zależności

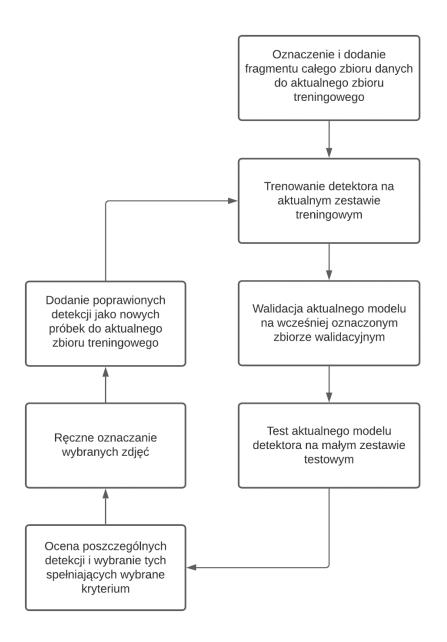
- Detektor: https://github.com/ultralytics/yolov3
- Zależności detektora (podane w pliku requirements.txt w repozytorium detektora)
- Narzędzie LabelMe: https://github.com/wkentaro/labelme
- Zależności skryptów realizujących LabelMe (podane w READMIE repozytorium)

5. Główne funkcjonalności

5.1. Petla realizująca Active Learning

Active Learning jest to metoda trenowania w uczeniu maszynowym, która pozwala aktywnie wybierać podzbiory zbioru trenującego, które mogą w największym stopniu poprawić wydajność. W przygotowaniu odpowiedniego zbioru danych do trenowania, najważniejszym aspektem jest różnorodność w każdej klasie, w czym właśnie pomaga Active Learning. Pętla Active Learning zaczyna się od wytrenowania detektora na zbiorze danych z oznaczonymi obiektami. Następnie detektor oznacza zbiór danych nieoznaczonych. Z tego zbioru danych bazując na wynikach, jakie osiągnął detektor podczas detekcji, wybieramy odpowiednie zdjęcia. Wybór zdjęć odbywa się poprzez analizę pewności detekcji detektora. Gdy jest ona mała, dane zdjęcie zostaje zakwalifikowane do ręcznej anotacji, a następnie dodania do zbioru uczącego. Na koniec detektor jest ponownie trenowany, ale już na nowym zbiorze trenującym, po czym pętla się powtarza.

Poniżej znajduje się stworzony przez nas schemat blokowy pętli Active Learning.



Rysunek 1. Schemat blokowy obrazujący ogólny przypadek Active Learningu

5.2. Uniwersalizacja komunikacji z detektorem

W ramach powyższej "pętli" napisano uchwyt obsługujący interfejs wykorzystywanego detektora. Uchwyt ten w dynamiczny sposób tworzy wywołania skryptów detektora, tak aby te mogły realizować aktualnie wybraną przez użytkownika funkcjonalność związaną z Active Learningiem. Dzięki temu, użytkownik zobowiązany jest jedynie do zdefiniowania swoich preferencji w pliku konfiguracyjnym. Takie podejście ułatwia również rozbudowę biblioteki o obsługę kolejnych detektorów (sieci), gdyż wymaga to jedynie utworzenie klasy obsługującej nowy detektor i dodanie jej metod do wcześniej opisanego interfejsu.

5.3. Zautomatyzowana ręczna anotacja

Stworzono skrypt, który miał za zadanie zautomatyzować proces ręcznej anotacji w LabelMe. Obrazki wybrane na podstawie pewności detekcji są zapisywane do nowego folderu, a następnie ten folder jest automatycznie wczytywany do Labelme. Gdzie

użytkownik ma możliwość anotować obiekty, które następnie są automatycznie zapisywane.

5.4. Tłumaczenie formatów zapisu anotacji obiektów

W związku z różnicą miedzy formatem zapisu anotacji wykorzystywanym w zbiorze COCO oraz obsługiwanym przez narzędzie label me i formatem wykorzystywanym przez detektor (i w efekcie też całą bibliotekę), napisano skrypt umożliwiający przetłumaczenie anotacji zapisanych w formacie JSON do formatu tekstowego, dającego większą prostotę i łatwość integracji z wykorzystywanym detektorem.

6. Instrukcja obsługi

6.1. Przygotowanie do pracy z biblioteką

Zakładając, że pracujemy na systemie operacyjnym Linux, przygotowanie do pracy z biblioteką należy zacząć od sklonowania repozytorium do dowolnego miejsca na dysku. W następnym kroku należy sklonować repozytorium obsługiwanego detektora oraz zainstalować narzędzie labelme. Następnie należy zainstalować zależności wymagane do działania obu tych narzędzi. Ostatnim krokiem jest utworzenie powiązania symbolicznego wewnątrz katalogu biblioteki, do katalogu z detektorem (polecenie *ln*).

6.2. Plik konfiguracyjny (opcjonalnie)

Następnym, opcjonalnym krokiem jest modyfikacja ustawień wewnątrz pliku konfiguracyjnego (*loop_options.yaml*). W przeciwnym wypadku uruchomione zostaną ustawienia domyślne. Poniżej wyjaśnione zostały kolejne opcje dostępne do modyfikacji:

- detector_name typ detektora, wstępnie obsługiwany jedynie "ultralytics_yolo", czyli ten wykorzystany w trakcie rozwijania biblioteki
- detector_path ścieżka do katalogu z detektorem, w naszym przypadku wcześniej utworzone powiązanie symboliczne
- train epochs liczba epok w fazie trenowania detektora
- train_batch rozmiar paczki danych wejściowych w fazie trenowania
- test_batch rozmiar paczki danych wejściowych w podczas detekcji (wykorzystywane w fazach walidacji i detekcji)
- proj_dir katalog projektowy, w którym zapisywane będą postępy pracy
- mute_stdout wyciszenie wyjścia standardowego detektora
- conf_ignore_threshold poziom pewności detekcji, poniżej którego detekcje nie będą zapisywane
- conf_sample_threshold poziom pewności detekcji, poniżej którego próbka zostanie wybrana do ręcznej anotacji
- validation_samples_amount liczba próbek do wykorzystania w fazie walidacji
- training_size_incrementaion procentowa część całości zbioru bazowego, jaka jest pobierana w każdej iteracji fazy trenowania
- whole dataset dir ścieżka do całego zbioru danych
- whole_dataset_images_dir ścieżka do anotacji całego zbioru danych

- train_dataset_dir zostanie utworzona, ścieżka przechowująca tymczasowy, aktualny zbiór do trenowania
- val_dataset_dir ścieżka do całości zbioru walidacyjnego
- train_labels zostanie utworzona, ścieżka przechowująca tymczasowe, aktualne anotacje zbioru do trenowania
- val_labels ścieżka do anotacji całości zbioru walidacyjnego
- *temp_val_labels* zostanie utworzona, ścieżka przechowująca tymczasowe anotacje do małego zbioru walidacyjnego
- temp_val_dataset_dir zostanie utworzona, ścieżka przechowująca tymczasowe anotacje do małego zbioru walidacyjnego

6.3. Wywołanie skryptu obsługującego bibliotekę

Interfejs biblioteki został zrealizowany poprzez wiersz poleceń. Skryptem wywoływanym jako główny interfejs w programie jest skrypt *loop.py.* Wywołanie skryptu z opcją *–help* lub *–h* wyświetli dokładny sposób wywołania skryptu. Do wywołania skryptu potrzebne są 2 opcje. Pierwsza z nich to –step, czyli konkretna faza pętli active learningu do wykonania dostępne opcje to:

- training
- detection
- validation
- select samples
- finish iteration

Drugą opcją, czyli –cfg jest ścieżka do pliku konfiguracyjnego.

7. Scenariusze użycia

7.1. Uzyskanie dostępu do biblioteki

SC/1	Uzyskanie dostępu do biblioteki		
Priorytet	1 (wymagane)	Status	Gotowe
Aktor	UżytkownikGitHub		
Warunki początkowe	 Użytkownik zaznajomiony jest z programowaniem w języku		

Zdarzenie inicjujące	Użytkownik zgłasza chęć skorzystania z biblioteki	
Przebieg w krokach	Pobranie kodu źródłowego biblioteki Załączenie biblioteki do tworzonego programu	
Przebiegi alternatywne	Instalacja poprzez komendę w terminalu	
Sytuacje wyjątkowe	 Niepełnie zainstalowane lub całkowicie niezainstalowanie zależności Niewspierana karta graficzna 	
Warunki końcowe	Możliwość zainstalowania i korzystania z biblioteki	
Powiązania	Korzystanie z biblioteki	
Źródło	Spotkania przeprowadzone zdalnie	
Częstotliwość wykonywania	Kilka rocznie	

7.2 Trenowanie wstępne detektora (użytkownik ma możliwość samodzielnego trenowania sieci, jeśli nie będzie chciał korzystać z wcześniej wytrenowanych)

SC/2	Trenowanie wstępne detektora		
Priorytet	1 (wymagane)	Status	Gotowe
Aktor	 Użytkownik 		
Warunki początkowe	 Uzyskanie wcześniejszego dostępu do biblioteki Posiadanie zbioru danych 		

Zdarzenie inicjujące	Załączenie biblioteki		
Przebieg w krokach	 Załączenie biblioteki Pobranie zbioru danych (posiadających etykiety) Wywołanie skryptu trenującego sieci detektora z parametrami (np. liczba epok, wagi początkowe) 		
Przebiegi alternatywne	Ręczne utworzenie etykiet		
Sytuacje wyjątkowe	 Postępowanie niezgodne z instrukcją zawartej w README repozytorium 		
Warunki końcowe	 Uzyskanie wyników trenowania (np. wagi i statystyki) 		
Powiązania	Uzyskanie dostępu do biblioteki		
Źródło	Spotkania przeprowadzone zdalnie		
Częstotliwość wykonywania	Kilka miesięcznie		

7.3 Trenowanie z użyciem Active Learning

SC/3	Trenowanie z użyciem Active Learning		
Priorytet	0 (opcjonalne)	Status	Gotowe
Aktor	 Użytkownik 		
Warunki początkowe	Trenowanie wstępne detektora		

Zdarzenie inicjujące	Posiadanie zbirów danych	
Przebieg w krokach	 Wybranie klas obiektów Wywołanie skryptu obsługującego Active Learning Weryfikacja przez użytkownika zwracanych detekcji o najmniejszej pewności Poprawa w przypadku błędnych detekcji Kolejne trenowanie na udoskonalonych danych 	
Przebiegi alternatywne		
Sytuacje wyjątkowe	 Postępowanie niezgodne z instrukcją zawartej w README repozytorium 	
Warunki końcowe	• Lepiej wytrenowana sieć	
Powiązania	 Trenowanie wstępne detektora 	
Źródło	Spotkania przeprowadzone zdalnie	
Częstotliwość wykonywania	Kilka miesięcznie	

7.4 Automatyczna anotacja obiektów

SC/4	Automatyczna anotacja obiektów		
Priorytet	1 (wymagane)	Status	Gotowe
Aktor	 Użytkownik 		

Warunki początkowe	Uzyskanie wcześniejszego dostępu do biblioteki	
Zdarzenie inicjujące	Załączenie biblioteki	
Przebieg w krokach	 Załączenie biblioteki Wywołanie skryptu do anotacji danych Ręczne anotowanie plików multimedialnych, które zostały wybrane do anotacji 	
Przebiegi alternatywne		
Sytuacje wyjątkowe	 Postępowanie niezgodne z instrukcją zawartej w README repozytorium 	
Warunki końcowe	Obraz z zaznaczonymi obiektami	
Powiązania	Uzyskanie dostępu do biblioteki	
Źródło	Spotkania przeprowadzone zdalnie	
Częstotliwość wykonywania	Kilka dziennie	